

# ALGORITMOS Y ESTRUCTURAS DE DATOS

## Maps y Tablas Hash

Guillermo Román Díez  
groman@fi.upm.es

Lars-Åke Fredlund  
lfredlund@fi.upm.es

Universidad Politécnica de Madrid

Curso 2021/2022

# Motivación

- La información almacenada puede ser compleja y difícilmente “organizable”

# Motivación

- La información almacenada puede ser compleja y difícilmente “organizable”
- Los **maps** permiten *organizar* la información usando una **clave** para *acceder* a la información
  - ▶ La inserción, la búsqueda y el borrado de información se harán mediante las claves

# Motivación

- La información almacenada puede ser compleja y difícilmente “organizable”
- Los **maps** permiten *organizar* la información usando una **clave** para *acceder* a la información
  - ▶ La inserción, la búsqueda y el borrado de información se harán mediante las claves
- Un **map** es un conjunto finito de entradas (clave-valor) donde todas las entradas tienen distinta clave
- Un **map** es una *función parcial* que dado un tipo el tipo de las claves al tipo de los valores:

*TipoClave*  $\rightarrow$  *TipoValor*

# Motivación

- La información almacenada puede ser compleja y difícilmente “organizable”
- Los **maps** permiten *organizar* la información usando una **clave** para *acceder* a la información
  - ▶ La inserción, la búsqueda y el borrado de información se harán mediante las claves
- Un **map** es un conjunto finito de entradas (clave-valor) donde todas las entradas tienen distinta clave
- Un **map** es una *función parcial* que dado un tipo el tipo de las claves al tipo de los valores:

*TipoClave*  $\rightarrow$  *TipoValor*

- A nivel de implementación, se podrá utilizar alguna propiedad de las claves que permitan *organizar* la información de forma eficiente

# Maps

- El requisito para poder implementar un  $\text{Map}\langle K, V \rangle$  es poder establecer una relación de igualdad entre dos elementos de tipo  $K$ 
  - ▶ Lo habitual es utilizar el método `equals` de  $K$  para comparar las claves

# Maps

- El requisito para poder implementar un `Map<K,V>` es poder establecer una relación de igualdad entre dos elementos de tipo `K`
  - ▶ Lo habitual es utilizar el método `equals` de `K` para comparar las claves
- Sería posible utilizar otros métodos, pero habitualmente no se usan
  - ▶ Si `K` implementa `Comparable<K>` se podría usar `compareTo`
  - ▶ Si se dispone de un `Comparator<K>` se podría usar el método `compare` del comparador

# Maps

- El requisito para poder implementar un `Map<K,V>` es poder establecer una relación de igualdad entre dos elementos de tipo `K`
  - ▶ Lo habitual es utilizar el método `equals` de `K` para comparar las claves
- Sería posible utilizar otros métodos, pero habitualmente no se usan
  - ▶ Si `K` implementa `Comparable<K>` se podría usar `compareTo`
  - ▶ Si se dispone de un `Comparator<K>` se podría usar el método `compare` del comparador
- Una implementación “sencilla” sería con una lista de entradas `<K,V>` (pares) sin claves repetidas



# Interfaz Map

```
public interface Map<K,V> extends Iterable<Entry<K,V>> {  
  
    public int size();  
  
    public boolean isEmpty();  
  
    public V put(K key, V value) throws InvalidKeyException;  
  
    public V get(K key) throws InvalidKeyException;  
  
    public boolean containsKey(Object key) throws  
        InvalidKeyException;  
  
    public V remove(K key) throws InvalidKeyException;  
  
    public Iterable<K> keys();  
  
    public Iterable<Entry<K,V>> entries();  
}
```

# Interfaz Map

- El método `put(key, value)` añade una nueva entrada en la tabla con clave `key`
  - ▶ En caso de que la entrada ya exista en el Map, se reemplaza el valor almacenado para la entrada `key` por `value`
  - ▶ Devuelve el valor que hubiera almacenado para `key` si ya existía previamente o `null` en caso de que se haya creado una nueva entrada
- El método `get(key)` devuelve el valor almacenado en la tabla para la entrada `key` (si la entrada no existe, devuelve `null`)
- El método `containsKey(key)` devuelve `true` si la clave `key` tiene entrada en el Map y `false` en caso contrario
- El método `remove(key)` elimina de la tabla la información y la entrada `key`
  - ▶ Devuelve el valor almacenado en `key` o `null` si no existía
- `keys()` y `entries()` devuelven un objeto iterable para recorrer las claves o los pares clave-valor

- Los métodos `get`, `put` y `remove` lanzan `InvalidKeyException` si la clave no es válida: p.e. `null`
- Notad que si `map.get(k)` devuelve `null`, puede ser porque:
  - ▶ no hay ninguna entrada con la clave `k`
  - ▶ o, el valor asociado con la clave `k` es `null`. Es decir, hemos ejecutado `map.put(k,null)` antes
- Se puede usar `map.containsKey(k)` para determinar si una entrada con la clave `k` realmente existe

# Interfaz Entry

```
public interface Entry<K,V> {  
    public K getKey();  
    public V getValue();  
}
```

- Básicamente un `Pair<K,V>` excepto no hay “setters” `setKey` y `setValue`

# Interfaz Entry

```
public interface Entry<K,V> {  
    public K getKey();  
    public V getValue();  
}
```

- Básicamente un `Pair<K,V>` excepto no hay “setters” `setKey` y `setValue`

## Pregunta

¿por qué no hay “setters”?

# Interfaz Entry

```
public interface Entry<K,V> {  
    public K getKey();  
    public V getValue();  
}
```

- Básicamente un `Pair<K,V>` excepto no hay “setters” `setKey` y `setValue`

## Pregunta

¿por qué no hay “setters”?

- Cambiar la clave podría ser difícil si el map está ordenado según la clave – hay que borrar el entry del map y después reinsertarlo

## Ejemplo de uso Map

```
Map<Character,Integer> map = new HashMap<...>();

map.put('a', 5); // El map tiene [<a,5>]
map.put('b', 8); // El map tiene [<a,5>, <b,8>]
map.put('c', 7); // El map tiene [<a,5>, <b,8>, <c,7>]

map.put('a', 10); // [<a,10>, <b,8>, <c,7>]

System.out.println(map.get('a')); // 10
System.out.println(map.get('b')); // 8
System.out.println(map.get('c')); // 7

map.remove('c');
System.out.println(map.get('c')); // null

System.out.println(map.get('d')); // null
map.put('d', null);
System.out.println(map.get('d')); // null
```

## Ejemplo de uso Map

*// Recorremos Claves*

```
Iterator<Character> itk = map.keys().iterator();  
while(itk.hasNext()) {  
    System.out.println(k + " " + map.get(itk.next()));  
}
```

```
for (Character c: map.keys()) {  
    System.out.println(k + " " + map.get(c));  
}
```

*// Recorremos entradas*

```
Iterator<Entry<Character,Integer>> ite = map.entries().  
    iterator();  
while(ite.hasNext()) {  
    Entry<Character,Integer> e = it.next();  
    System.out.println(e.getKey() + "—" + e.getValue());  
}
```

```
for(Entry<Character,Integer> e: map.entries()){  
    System.out.println(e.getKey() + "—" + e.getValue());  
}
```



# Implementaciones de `Map`

- Una posible implementación sería con una lista no ordenada de elementos de tipo  $\langle K, V \rangle$

# Implementaciones de `Map`

- Una posible implementación sería con una lista no ordenada de elementos de tipo  $\langle K, V \rangle$
- Todos los métodos necesitan buscar si el elemento existe, por tanto la complejidad es  $O(n)$

get             $O(n)$

put             $O(n)$

remove        $O(n)$

# Implementaciones de Map

- Una posible implementación sería con una lista no ordenada de elementos de tipo  $\langle K, V \rangle$
- Todos los métodos necesitan buscar si el elemento existe, por tanto la complejidad es  $O(n)$

get	$O(n)$
put	$O(n)$
remove	$O(n)$

## Pregunta

¿y no se puede mejorar esto?

# Implementaciones de Map

- Una posible implementación sería con una lista no ordenada de elementos de tipo  $\langle K, V \rangle$
- Todos los métodos necesitan buscar si el elemento existe, por tanto la complejidad es  $O(n)$

get	$O(n)$
put	$O(n)$
remove	$O(n)$

## Pregunta

¿y no se puede mejorar esto?

- Sí, si las claves son *comparables* –  $O(\log n)$

## Implementaciones de Map

- Una posible implementación sería con una lista no ordenada de elementos de tipo  $\langle K, V \rangle$
- Todos los métodos necesitan buscar si el elemento existe, por tanto la complejidad es  $O(n)$

get	$O(n)$
put	$O(n)$
remove	$O(n)$

### Pregunta

¿y no se puede mejorar esto?

- Sí, si las claves son *comparables* –  $O(\log n)$
- Sí, usando funciones finitas y tablas de dispersión –  $O(1)$  (coste medio)

# Tablas Hash

- El objetivo es implementar un Map cuyas operaciones tengan en complejidad  $O(1)$
- Para ello, las claves tienen que ser *dispersables*

# Tablas Hash

- El objetivo es implementar un Map cuyas operaciones tengan en complejidad  $O(1)$
- Para ello, las claves tienen que ser *dispersables*
- Utilizaremos una **función de codificación** o **función hash**
  - ▶ El objetivo de la *función hash* es, dada una clave, devolver un valor numérico dentro de un determinado rango  $[0..K - 1]$

# Tablas Hash

- El objetivo es implementar un Map cuyas operaciones tengan en complejidad  $O(1)$
- Para ello, las claves tienen que ser *dispersables*
- Utilizaremos una **función de codificación** o **función hash**
  - ▶ El objetivo de la *función hash* es, dada una clave, devolver un valor numérico dentro de un determinado rango  $[0..K - 1]$
- Se utilizará una **función de compresión/dispersión** para que todos los posibles *hash codes* se compriman y distribuyan al rango  $[0..N - 1]$



# Tablas Hash

- El objetivo es implementar un Map cuyas operaciones tengan en complejidad  $O(1)$
- Para ello, las claves tienen que ser *dispersables*
- Utilizaremos una **función de codificación** o **función hash**
  - ▶ El objetivo de la *función hash* es, dada una clave, devolver un valor numérico dentro de un determinado rango  $[0..K - 1]$
- Se utilizará una **función de compresión/dispersión** para que todos los posibles *hash codes* se compriman y distribuyan al rango  $[0..N - 1]$
- Usaremos un array de tamaño  $N$  como **tabla de dispersión**

# Tablas Hash

- Dada una función hash que codifica en un rango  $[0..K - 1]$  y un objeto `key` como clave
- Dada una función de compresión/dispersión que trabaja en un rango  $[0..N - 1]$
- Usaremos un array `arr` de tamaño  $N$  para almacenar la tabla
- La secuencia de operaciones sería:
  - ➊ Dado un objeto `o` obtenemos su *hash code* (p.e. método `hashCode` de `Object`)
  - ➋ Aplicamos la función de compresión/dispersión (`comprimir`) sobre el *hash code* obtenido
  - ➌ La entrada `arr[comprimir(o.hashCode())]` almacenará la información referente al objeto `o`

# Tablas Hash

- Dada una función hash que codifica en un rango  $[0..K - 1]$  y un objeto `key` como clave
- Dada una función de compresión/dispersión que trabaja en un rango  $[0..N - 1]$
- Usaremos un array `arr` de tamaño  $N$  para almacenar la tabla
- La secuencia de operaciones sería:
  - ➊ Dado un objeto `o` obtenemos su *hash code* (p.e. método `hashCode` de `Object`)
  - ➋ Aplicamos la función de compresión/dispersión (`comprimir`) sobre el *hash code* obtenido
  - ➌ La entrada `arr[comprimir(o.hashCode())]` almacenará la información referente al objeto `o`
- La obtención de `hashCode` debe tener complejidad  $O(1)$
- La aplicación de la función `comprimir` también debe ser  $O(1)$
- Los accesos a `arr[i]` tienen complejidad  $O(1)$

# Colisiones

## Pregunta

¿podemos obtener la misma posición del array para dos objetos distintos?

# Colisiones

## Pregunta

¿podemos obtener la misma posición del array para dos objetos distintos?

- Sí. Decimos que se ha producido una **colisión**

# Colisiones

## Pregunta

¿podemos obtener la misma posición del array para dos objetos distintos?

- Sí. Decimos que se ha producido una **colisión**

## Pregunta

¿cómo se puede producir una colisión?

# Colisiones

## Pregunta

¿podemos obtener la misma posición del array para dos objetos distintos?

- Sí. Decimos que se ha producido una **colisión**

## Pregunta

¿cómo se puede producir una colisión?

- Si el `hashCode` de dos objetos es el mismo
- Si la función de compresión devuelve la misma dirección aunque tengamos dos *hash code* distintos

## Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:



## Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:
  - ▶ `o1.hashCode() != o2.hashCode() && !o1.equals(o2)`

## Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:
  - ▶ `o1.hashCode() != o2.hashCode() && !o1.equals(o2)`
    - ★ OK. Son dos objetos distintos, dos entradas distintas en el map

# Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:
  - ▶ `o1.hashCode() != o2.hashCode() && !o1.equals(o2)`
    - ★ OK. Son dos objetos distintos, dos entradas distintas en el map
  - ▶ `o1.hashCode() == o2.hashCode() && o1.equals(o2)`

# Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:
  - ▶ `o1.hashCode() != o2.hashCode() && !o1.equals(o2)`
    - ★ OK. Son dos objetos distintos, dos entradas distintas en el map
  - ▶ `o1.hashCode() == o2.hashCode() && o1.equals(o2)`
    - ★ OK. Una única entrada en el map

# Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:
  - ▶ `o1.hashCode() != o2.hashCode() && !o1.equals(o2)`
    - ★ OK. Son dos objetos distintos, dos entradas distintas en el map
  - ▶ `o1.hashCode() == o2.hashCode() && o1.equals(o2)`
    - ★ OK. Una única entrada en el map
  - ▶ `o1.hashCode() == o2.hashCode() && !o1.equals(o2)`

# Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:
  - ▶ `o1.hashCode() != o2.hashCode() && !o1.equals(o2)`
    - ★ OK. Son dos objetos distintos, dos entradas distintas en el map
  - ▶ `o1.hashCode() == o2.hashCode() && o1.equals(o2)`
    - ★ OK. Una única entrada en el map
  - ▶ `o1.hashCode() == o2.hashCode() && !o1.equals(o2)`
    - ★ Colisión. No hay problema, dos entradas distintas en el map

# Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:
  - ▶ `o1.hashCode() != o2.hashCode() && !o1.equals(o2)`
    - ★ OK. Son dos objetos distintos, dos entradas distintas en el map
  - ▶ `o1.hashCode() == o2.hashCode() && o1.equals(o2)`
    - ★ OK. Una única entrada en el map
  - ▶ `o1.hashCode() == o2.hashCode() && !o1.equals(o2)`
    - ★ Colisión. No hay problema, dos entradas distintas en el map
  - ▶ `o1.hashCode() != o2.hashCode() && o1.equals(o2)`

# Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:
  - ▶ `o1.hashCode() != o2.hashCode() && !o1.equals(o2)`
    - ★ OK. Son dos objetos distintos, dos entradas distintas en el map
  - ▶ `o1.hashCode() == o2.hashCode() && o1.equals(o2)`
    - ★ OK. Una única entrada en el map
  - ▶ `o1.hashCode() == o2.hashCode() && !o1.equals(o2)`
    - ★ Colisión. No hay problema, dos entradas distintas en el map
  - ▶ `o1.hashCode() != o2.hashCode() && o1.equals(o2)`
    - ★ Inconsistente. Si los objetos son iguales deberían tener el mismo `hashCode`
    - ★ Se producen dos entradas distintas en el map, teniendo dos objetos iguales (de acuerdo al resultado de `equals`)



# Implementando `equals` y `hashCode`

- Es necesario que haya *coherencia* entre `equals` y `hashCode`
- Dados `o1` y `o2` usados como claves puede ocurrir:
  - ▶ `o1.hashCode() != o2.hashCode() && !o1.equals(o2)`
    - ★ OK. Son dos objetos distintos, dos entradas distintas en el map
  - ▶ `o1.hashCode() == o2.hashCode() && o1.equals(o2)`
    - ★ OK. Una única entrada en el map
  - ▶ `o1.hashCode() == o2.hashCode() && !o1.equals(o2)`
    - ★ Colisión. No hay problema, dos entradas distintas en el map
  - ▶ `o1.hashCode() != o2.hashCode() && o1.equals(o2)`
    - ★ Inconsistente. Si los objetos son iguales deberían tener el mismo `hashCode`
    - ★ Se producen dos entradas distintas en el map, teniendo dos objetos iguales (de acuerdo al resultado de `equals`)
- Si el objeto implementa `Comparable`, también se debe conservar la coherencia con `compareTo`

# Algunas funciones de codificación

## NOTA!!

El objetivo fundamental de la *función de codificación* es que se generen las menores colisiones posibles

- El método `hashCode` de `Object` devuelve el `int` que representa la dirección de memoria de un objeto
- Si el tamaño del dato es  $\leq 32\text{bits}$  (`byte`, `char`, ...) podemos hacer un casting a `int`
- Si el tamaño es  $> 32\text{bits}$  (`long`, `double`) se puede hacer la “suma binaria de las dos palabras que lo componen”
- Se puede hacer un *Polynomial hash code* (p.e. `String` de Java):

$$s[0] * 31^{n-1} + s[1] * 31^{n-2} + \dots + s[n-1]$$

donde  $s[i]$  es la letra  $i$  del `String`  $s$ ,  $n$  es la longitud de  $s$ , y  $a^b$  es exponenciación

- Desplazamiento binario cíclico (*cyclic shift*)

# Algunas Funciones de compresión/dispersión

## NOTA!!

El objetivo fundamental de una *función de compresión/dispersión* es que se generen las menores colisiones posibles

- La función de compresión debe pasar del rango  $i \in [0..K]$  devuelto por hashCode a un rango  $[0..N]$  que es el tamaño del array
- La más sencilla sería el “*division method*”:

$$i \bmod N$$

- El método *MAD* (*multiply-add-and-divide*):

$$[(a \cdot i + b) \bmod p] \bmod N$$

- ▶  $p > N$  y  $p$  es primo
- ▶  $a$  y  $b$  son números aleatorios en  $[0..p-1]$  y  $a > 0$

# Solucionando las colisiones

- **Separate Chaining:** Cada uno de los elementos del array son listas y usar equals para buscar el elemento
  - ▶ Se puede usar un Map implementado con una lista
- Técnicas de **open addressing**
  - ▶ **Linear Probing:** Si la posición del array está ocupada, uso la siguiente posición (circularmente)
  - ▶ **Quadratic Probing:** Si hay colisión, calcula la siguiente opción usando una función  $(i + j^2) \bmod N$  con  $j = 0, 1, 2 \dots$
  - ▶ **Double Hashing:** Si hay colisión, calcula la siguiente opción usando una función  $(i + \text{otrohash}(j)) \bmod N$  con  $j = 0, 1, 2 \dots$